ИИ-КОНСУЛЬТАНТ ДЛЯ САЙТА

# От бизнес-вопроса к заявке

EnergyTool · кейс МТС · начальный прототип команды

01

## Описать задачу

Клиент формулирует ситуацию своими словами.

02

## Разобраться

Поиск материалов и консультация с учётом диалога.

03

## Продолжить

Локальная заявка с контекстом разговора.

**Репозиторий проекта**

https://github.com/snezhok-prog/hack-change-2026-mts-ai

Проверка: .env и data/ по README → docker compose up --build → localhost:8000.

Вопрос → уточнение → тестовая заявка → новый диалог → архив. Подробно: docs/demo/scenario.md

ПОЛЬЗОВАТЕЛЬСКИЙ ПУТЬ

# Пять шагов в одном интерфейсе

Консультация и заявка связаны одной сессией.

| | | |
|---|---|---|
| 01 | **Задача** | Описать проблему бизнеса без технической анкеты. |
| 02 | **Уточнение** | Добавить исходные данные по вопросу консультанта. |
| 03 | **Ответ** | Получить объяснение; открыть источники и время. |
| 04 | **Контакты** | По желанию заполнить отдельную форму заявки. |
| 05 | **Результат** | Увидеть локально сохранённую заявку и резюме. |

В учебном прототипе используются только выдуманные контакты. Внешней отправки нет.

АРХИТЕКТУРА

# Одно ядро. Два способа запуска.

Локальный поиск BM25 и вызов API модели используются в вебе и CSV-сабмите.

### База знаний

ZIP → Markdown → секции

### Поиск BM25

Релевантные фрагменты

### Консультант

Контекст + диалог → модель

**WEB**

FastAPI · SQLite · HTML/CSS/JS

**BATCH**

solution.py → submission.csv

Docker Compose — локальный запуск. Плотный поиск и реранкер пока относятся к плану.

ОБОСНОВАННОСТЬ

# Источники видны. Факты проверяются.

Продуктовые факты ограничены предоставленными материалами.

01

## Контекст

В модель передаются найденные фрагменты и текущий диалог.

02

## Отладка

Интерфейс показывает найденные источники и время ответа.

03

## Границы

Промпт требует не выдумывать условия и предлагать специалиста.

Найденный источник и системный промпт не гарантируют достоверность каждого утверждения.

ПРОВЕРКИ

# Что подтверждено сейчас

Синтетические тесты проверяют работу кода; качество модели измеряется отдельно.

| | |
|---|---|
| **КОД** | Поиск, CSV, веб-чат, история, заявки и сборщик ZIP присутствуют. |
| **CI / УСПЕХ** | Тесты, ZIP, контейнер, HTTP и сохранение SQLite после перезапуска. |
| **ЖИВАЯ МОДЕЛЬ** | Качество, факты и скорость пока не подтверждены в этой работе. |
| **ПЛАТФОРМА** | Первая попытка: «Не хватает данных в решении». Балла нет. |

Источник: GitHub Actions · run 42684281251 · commit 2ed811b

Результаты CI указаны для конкретного коммита. Это не оценка LLM-судьи организаторов.

ДЕМОНСТРАЦИЯ

# От вопроса до истории диалога

План показа на 60–90 секунд; полный сценарий — 3–5 минут.

01

## Консультация

Задача трёх складов → уточнение → ответ с источниками.

02

## Заявка

Выдуманные контакты → сохранение → резюме диалога.

03

## Новая сессия

Очистка контекста → просмотр сохранённой истории.

Живой прогон ещё не выполнен. При сбое API показываем ошибку, без заготовленного ответа.

НАДЁЖНОСТЬ И ОГРАНИЧЕНИЯ

# Локальное демо с сохранением истории

Текущая версия предназначена для localhost и тестовых данных.

## Реализовано

- Изолированные сессии и SQLite
- Обработка ошибок API
- Заявка без внешней отправки
- Ключ просмотра списка архива

## Ограничения

- Один процесс приложения
- Архив: последние 100 сессий
- Резюме собирается из переписки
- Публичный запуск требует защиты

Секреты — через окружение. Материалы организаторов и реальные контакты в git не входят.

ПЕРЕД ЗАЩИТОЙ

# Три шага до подтверждённой готовности

Следующий этап — реальные проверки и финальная репетиция.

01

## Проверить модель

Демо-вопросы, достоверность фактов, качество и задержка.

02

## Проверить платформу

Временной бюджет, ZIP, принятый сабмит и результат.

03

## Провести репетицию

Полный веб-сценарий, разрешённые кадры и финальный PDF.

Основание макета: main edfba52. Срок и комплект сдачи сверить на платформе.